AD-Rank：对流-扩散图排序 — 通用向量检索增强算法

日期：2026-03-24（v2，基于研究讨论大幅修订）
作者：一凡
状态：灵感成型 → 准备实验

一、核心思想

1.1 一句话定位

AD-Rank（Advection-Diffusion Ranking） 是一种通用的向量检索增强算法：只要你有一组 embedding 向量和一个 query 向量，AD-Rank 就能给出比 cosine similarity 更好的排序结果。

1.2 为什么现有方法不够好

现有方法	本质	缺陷
Cosine Similarity	逐条对比，独立打分	忽略文档之间的语义关系
RRF 融合	多路排名合并	仍然是独立排名的拼接
Cross-Encoder Rerank	深度语义匹配	计算昂贵，O(n×seq)
Diffusion-Aided RAG (2025)	图上各向同性扩散	**无方向性**，扩散无偏好

1.3 AD-Rank 的核心创新

在文档构成的语义图上求解 **对流-扩散方程**：

```
ΔC = Δt × [ -u · ∇C + D · L · C ]
       对流项↑      扩散项↑
```

- **对流项** `u · ∇C`：query 方向驱动语义浓度”流向”正确区域 → **方向性检索**
- **扩散项** `D · L · C`：相邻文档之间自然扩散 → **发现关联文档**

这是 Diffusion-Aided RAG 的超集：他们只有扩散项，我们多了对流项。

1.4 通用接口

```
results = ad_rank(
    query_vector,    # 任意维度的 query embedding
    doc_vectors,     # 候选文档 embedding 列表
    k=10             # 返回 top-k
)
# 适用于：法律检索、论文搜索、企业知识库、代码搜索...任何 embedding 场景
```

二、查重与定位

2.1 最相关的已有工作

工作	相关度	与我们的关键区别
Diffusion-Aided RAG (2025, ACL)	⚠️ 最相关	图上纯扩散重排序。无对流项，无方向性，无流场拓扑分析
G-RAG (2025, arXiv)	高	用 GNN 做 RAG 重排序，考虑文档间连接。但不是扩散方程框架
SLoD (2026.03, arXiv)	中	热核扩散+庞加莱球做多尺度知识表示。无对流项，不用于检索
G-DSR (ACL)	中	图增强法条检索，GNN 方法，非扩散方程
Semantic Physics (ResearchGate)	低	热力学框架建模语义，概念性工作，无实现
Flow Matching (ICML 2025)	低	学习向量场做生成模型，非检索

2.2 原创性声明

> “Diffusion-Aided RAG 证明了图扩散可以改善 RAG 检索质量。我们在此基础上引入 **对流项**，将 query 建模为图上的定向语义流，实现 **方向性检索**。同时，通过对流-扩散稳态场的 **拓扑分析**（汇聚点、发散点、停滞点），为 Prompt 构建提供结构化语义信号。”

2.3 原创部分精确列表

创新点	原创度	说明
图上对流-扩散方程用于检索排序	✅ 原创	无先例
流场拓扑分析（汇聚/发散/停滞点）用于 Prompt 构建	✅ 原创	无先例
语义雷诺数作为统一复杂度度量	✅ 原创	小创新
图扩散用于 RAG	❌ 非原创	Diffusion-Aided RAG 已做
谱方法/图信号处理	❌ 非原创	成熟领域

三、数学框架

3.1 核心物理量映射

CFD 物理量	语义检索对应	映射自然度
对流速度 u	query embedding 的方向	★★★★☆
浓度场 C	每个文档的相关度分数	★★★★★
扩散系数 D	语义邻域的传播强度	★★★★☆
雷诺数 Re		对流项
~~压力场 p~~	~~无对应~~	❌ 不映射
~~粘性 ν~~	~~无对应~~	❌ 不映射

3.2 核心方程

对流-扩散方程（图上离散化）：

```
∂C/∂t + u·∇C = D·∇²C

图上离散化:
  C_{t+1} = C_t + Δt × [-u · (∇C)_graph + D · L · C_t]

其中:
  C = N维向量，每个分量是一个文档的"语义浓度"
  L = 图拉普拉斯矩阵 (D_degree - W_similarity)
  u = query 在图上的方向投影
  D = 扩散系数（可全局固定，也可按领域/层级调整）
```

3.3 与已有方法的方程对比

方法	方程	方向性
SLoD	$\partial T/\partial t = \alpha \nabla^2 T$（纯扩散）	❌ 无
Diffusion-Aided RAG	$C = \exp(-\beta L)\cdot C_0$（图扩散核）	❌ 无
AD-Rank（我们）	$\partial C/\partial t + \mathbf{u}\cdot\nabla \mathbf{C} = D\nabla^2 C$	✅ 有
完整 N-S（原始方案，已放弃）	$\partial u/\partial t + (u\cdot\nabla)u = -\nabla p + \nu\nabla^2 u$	✅ 有，但物理假设不成立

四、算法流程

4.0 分块自适应对流（Block-Adaptive Advection, BAA）⭐新

> 灵感来源：NVIDIA FP8→FP4 量化的分块缩放 + CUDA Tensor Core 并行

核心思想：不在全局 d 维空间定义一个对流方向，而是把向量分块，每块有独立的流场方向。

```
分块:
  query = [q₁, q₂, ..., q_B]     B 块，每块 d/B 维（如 64块×64维）
  doc_i = [d₁ⁱ, d₂ⁱ, ..., d_Bⁱ]

每块权重（量化 scale factor 的类比）：
  w_b = ||q_b|| / ||query||       ← query 在第 b 块的"能量"占比

每块独立建图 + 独立对流方向:
  sim_b(i,j) = cos(d_bⁱ, d_bʲ)   ← 只看这 d/B 维
  u_b = q_b / ||q_b||             ← 第 b 块独立的对流方向
  L_b = 基于 sim_b 的图拉普拉斯

每块独立求解:
  C_b_{t+1} = C_b_t + Δt × [-u_b · ∇C_b + D_b · L_b · C_b]

跨块融合（CUDA 多张量并行类比）：
  C_final[i] = Σ_b w_b × C_b[i]
             + λ × Σ_{b1≠b2} corr(C_b1, C_b2) × min(C_b1[i], C_b2[i])
               ↑ 跨块一致性增强
```

与已有工作的区别:

工作	做什么	我们的区别
Query-Aware Dim Selection (arXiv)	逐维度 mask 不重要维度	我们在每块上跑独立对流-扩散
Multi-Head RAG (ACL)	多 attention head 独立检索	我们用物理方程而非注意力机制
Product Quantization	子空间独立量化	我们做检索排序而非压缩

计算开销：B 块并行，每块图更小，总耗时约 10-20ms（比单一全局版慢 5-10 倍，但仍远快于 Cross-Encoder）。

4.1 完整管线（基础版）

```
输入: query_vector (d维), doc_vectors (N×d维), k

Step 1: 建图（零信息损失）
  • N个文档向量 → 计算两两 cosine similarity（在原始 d 维空间）
  • 取 KNN (k=5-10) 建稀疏图 → 邻接矩阵 W
  • 图拉普拉斯 L = D_degree - W

Step 2: 初始化场量
  • C₀[i] = cosine_sim(query, doc_i)    ← 初始浓度 = 原始相似度
  • u[i→j] = projection of (doc_j - doc_i) onto query direction
    ← 对流方向 = query 在图边上的投影

Step 3: 迭代求解（5-10步）
  • C_{t+1} = C_t + Δt × [-u·∇C + D·L·C_t]
  • 直到 ||C_{t+1} - C_t|| < ε 或达到最大步数

Step 4: 流场拓扑分析
  • 汇聚点: ∇·(u·C) < 0 的节点区域 → 多文档支持同一结论
  • 发散点: ∇·(u·C) > 0 的节点区域 → 观点分歧
  • 停滞点: |∂C/∂t| ≈ 0 且 C 值中等 → 语义矛盾尖锐处
  • Re = |对流项|/|扩散项| → 查询复杂度指标

Step 5: 输出
  • 按 C_final 排序 → Top-k 结果
  • 附加: 流场拓扑标签（汇聚/发散/停滞）
  • 附加: Re 值（可用于下游模型选择或 Prompt 策略）
```

4.2 计算复杂度

步骤	操作	复杂度	30个候选耗时
建图	N^2 cosine similarity	$O(N^2d)$	~1ms
初始化	赋值	$O(N)$	<0.1ms
迭代	稀疏矩阵乘法 ×10	$O(10 \cdot N \cdot k_nn)$	~0.5ms
拓扑分析	梯度+分类	$O(N)$	~0.2ms
总计			**< 2ms**

4.3 关键设计决策

为什么不降维?

- PCA 把 4096 维降到 3 维会丢失 75-90% 的信息
- 我们在图上操作，图的边权重用原始高维 cosine similarity 计算
- 零信息损失

为什么不用完整 N-S 方程?

- N-S 需要质量守恒、动量守恒 → embedding 空间不满足
- 对流-扩散方程只需要”浓度场”和”速度场” → 都有自然对应
- 计算量差 100 倍

为什么不用网格/有限体积?

- 高维空间无法网格化（维度诅咒）
- 图上离散化天然适配文档集合（文档=节点）
- 与现有向量数据库完美兼容

五、流场拓扑分析（第二层创新）

5.1 CFD 流场概念 → Prompt 构建

流场拓扑	检索含义	Prompt 策略
汇聚流	多文档支持同一结论	放一起，增强论证
发散流	文档观点矛盾	分开放，触发辩证分析
停滞点	语义矛盾最尖锐处	提示 LLM 重点推理
流线顺序	信息从前提到结论	按流线排列 Prompt

5.2 雷诺数动态调参

```
Re_semantic = |对流项| / |扩散项|

低Re → 层流 → 简单查询 → 轻量模型，temp=0.3
中Re → 过渡流 → 中等查询 → 标准模型，temp=0.5
高Re → 湍流 → 复杂查询 → 推理模型，temp=0.7
```

六、可扩展的 CFD 概念库

6.1 已纳入方案的 CFD 概念

CFD 概念	映射	优先级
对流-扩散方程	图上方向性检索排序	★★★★★
雷诺数	query 复杂度统一度量	★★★★☆
流场拓扑分析	汇聚/发散/停滞点 → Prompt 构建	★★★★☆
AMR（自适应网格细化）	热门语义区域用密集图，冷门用稀疏图	★★★★☆
涡量（Vorticity）	同一文档被不同方向引用 → 涡量大=争议大	★★★★☆
边界条件	检索约束（”只在某领域范围内”）	★★★★☆
收敛判断	多次迭代结果变化小→自动停止	★★★★☆
湍流模型（RANS）	模糊 query → 用统计平均替代精确求解	★★★☆☆
边界层	领域交叉处的检索策略调整	★★★☆☆
激波	语义突变检测	★★★☆☆
多相流（Multiphase）	不同类型文档=不同”相”，跨类型=相界面传输	★★★☆☆

6.2 CFD × AI 顶刊前沿方法（2024-2025）

前沿方法	发表	核心思想	映射到 AD-Rank
FNO（傅里叶神经算子）	ICLR 2021, NeurIPS 2024	频域学习 PDE 解算子，比传统快 1000-60000 倍	在谱域做对流-扩散滤波
PINN（物理信息神经网络）	JCP 2024, J.Fluid Mech 2025	方程嵌入 loss，无需网格	把对流-扩散方程作为训练约束
ML4CFD Competition	NeurIPS 2024	PINN + GNN 做翼型=图+物理方程	证明了”图+物理方程”范式有效
Advection Augmented CNN	NeurIPS 2024	对流-扩散-反应方程增强 CNN	直接证据：对流-扩散可增强 AI
LBM + LES	Physics of Fluids 2024	离散格子+大涡模拟，天然并行	文档=格子节点的替代框架
降阶模型 (ROM)	多刊 2024-2025	预计算基函数，在线快速求解	离线谱分解，在线毫秒级滤波
PI-GANO	2024	同时泛化 PDE 参数和几何	自适应不同知识库形状
无网格粒子法 (MPS/SPH)	欧洲无网格CFD会议 2025	“下一代数值方法”，无网格	文档=粒子，核函数交互

关键发现：NeurIPS 2024 ML4CFD 竞赛证明了 **图神经网络 + 物理方程 = CFD 问题最前沿解法**。我们的 AD-Rank 和这个范式结构完全一致（KNN图 + 对流-扩散方程），只是应用领域不同。

详细论文信息见 → 参考论文清单.md

七、实验设计

7.1 三组对比

```
组A（基线）：纯向量检索
  → embedding + cosine similarity
  → 无任何额外算法

组B（现有 SOTA）：图扩散重排（Diffusion-Aided RAG 复现）
  → 建图 + 纯扩散核 exp(-βL) + 重排
  → 代表"现有方案的上限"

组C（AD-Rank）：对流-扩散图排序
  → 建图 + 对流-扩散方程 + 流场拓扑
  → 我们的方法
```

7.2 评估指标

指标	说明
Top-K 命中率	正确文档是否在前 K 个结果中
MRR	正确文档的平均排名倒数
NDCG@K	归一化折损累积增益
延迟	检索耗时（ms）

7.3 数据集

- **法律**（自有）：25,069 chunk，30-50 个标注 query
- **通用**（公开基准）：MS MARCO / NQ / HotpotQA 等标准 IR 数据集
- 先在法律数据上验证，再在公开基准上证明通用性

7.4 执行优先级

```
第一步（1-2天）：实现 AD-Rank 核心算法
  → 建图 + 对流-扩散迭代 + 输出排序
  → 最小可运行版本

第二步（2-3天）：三组对比实验
  → 在法律数据集上跑 A/B/C 三组
  → 看 AD-Rank 是否优于纯扩散

第三步（1周）：流场拓扑分析 + 可视化
  → 汇聚/发散/停滞点分类
  → 2D 降维可视化 demo

第四步（可选）：公开基准实验
  → 在 MS MARCO 等数据集上验证通用性
```

八、风险与诚实评估

风险	严重性	应对
对流项对排序没有实际改善	⚠️ 高	先跑实验，效果不好也是有价值的结论（证伪）
对流方向的定义不唯一	⚠️ 中	尝试多种定义方式做消融实验
图建构方式影响结果	⚠️ 中	KNN 的 k 值做超参搜索
计算开销未必值得（比 cosine 慢但不比 cross-encoder 快）	低	2ms 级别可接受
被评委质疑”为什么用 CFD 方程”	⚠️ 高	回答：对流项=方向性是核心区别，不依赖 N-S 物理假设

综合评分

```
原创性:       7/10 — 对流项+流场拓扑是真正的新贡献
可行性:       7/10 — 图上离散化方案解决了降维问题
通用性:       8/10 — 任何 embedding+检索场景均适用
比赛适配度:   8/10 — 故事好讲、demo好做、和现有方案有明确对比
发论文潜力:   6/10 — 需要正向实验结果支撑
```

九、参考文献

直接竞品（5篇）

1. **Diffusion-Aided RAG** — Dampanaboina et al., 2025, ACL. 图扩散重排序用于 RAG（我们的”VCP”）
2. **G-RAG** — 2025, arXiv. GNN 重排序结合文档连接和语义信息
3. **G-DSR** — ACL. 图增强法条检索（法律领域直接相关）
4. **SLoD** — Izgorodin, 2026.03, arXiv. 热核扩散+庞加莱球多尺度知识表示
5. **Spreading Activation for KG-RAG** — 2025, arXiv. 知识图谱激活传播增强 RAG

CFD × AI 前沿（6篇）

1. **FNO** — Li et al., ICLR 2021 + NeurIPS 2024. 傅里叶神经算子，频域 PDE 求解
2. **PINN** — Raissi et al., JCP 2019 + 2024-2025 变体. 物理信息神经网络
3. **NeurIPS ML4CFD** — NeurIPS 2024 Competition. PINN+GNN 做翼型设计
4. **Advection Augmented CNN** — NeurIPS 2024. 对流-扩散-反应增强 CNN
5. **PI-GANO** — 2024. 物理信息几何感知神经算子
6. **MPS/SPH 无网格粒子法** — 欧洲无网格 CFD 会议 2025

数学基础（4篇）

1. **Diffusion Kernels on Graphs** — Kondor & Lafferty, ICML 2002. 图扩散核经典论文
2. **Heat Kernel PageRank** — Chung, 2007. 热核=特殊 PageRank
3. **Spectral Graph Filtering** — SIGIR 2025. 切比雪夫谱滤波用于推荐
4. **Tensor Train for High-Dim PDE** — 2024-2025 arXiv. 高维传输方程的 TT 分解

> 完整论文信息、摘要与关系图见 → 参考论文清单.md

十、今日进度（2026-03-24）

已完成

- [x] **方案重构**：从”法律 CFD-RAG”重新定位为”AD-Rank 通用向量检索增强算法”
- [x] **文献查重**：搜索并确认无完全重合论文，定位 Diffusion-Aided RAG (ACL 2025) 为”我们的 VCP”
- [x] **数学框架**：确定对流-扩散方程（图上离散化），放弃完整 N-S 和网格化
- [x] **分块自适应对流 (BAA)**：提出 FP8→FP4 量化启发的分块方案，每块独立流场 + CUDA 式并行融合
- [x] **CFD 前沿调研**：搜索 2024-2025 顶刊，整理 FNO/PINN/LBM-LES/ROM 等 8 项前沿方法
- [x] **论文清单**：整理 15 篇参考论文，分三类（竞品/CFD前沿/数学基础）
- [x] **技术全景图**：7 张 Mermaid 图覆盖架构、问题、路线
- [x] **3D Demo**：Three.js 交互动画展示对流-扩散过程
- [x] **原创性确认**：逐项标注原创/非原创部分，确认”对流项 + 流场拓扑 + 分块 BAA”组合无先例

未完成

- [ ] AD-Rank 核心代码实现
- [ ] 三组对比实验（cosine vs 纯扩散 vs 对流-扩散）
- [ ] 实验数据分析
- [ ] 参赛报告/论文撰写

十一、灵感清单

✅ 已验证并纳入方案

#	灵感	来源	纳入位置
1	对流项 = 方向性检索	N-S 方程精简	核心方程 §3
2	不降维，图上操作	降维丢信息 + 维度诅咒	设计决策 §4.3
3	张量分块处理	GPU Tensor Core / AVX-512	零信息损失原则
4	全局语义场替代逐条对比	“判断整个语义”	谱方法方向 §3
5	通用化（不绑定法律）	“任何向量化文档都能用”	定位 §1
6	FP8→FP4 分块加权	NVIDIA 量化过程	BAA方案 §4.0
7	CUDA 多张量并行融合	跨块交互处理	BAA方案 §4.0

⏳ 未展开的灵感（明天讨论）

#	灵感	一句话描述
8	Zen5 分支预测	预测用户下一个问题方向，提前计算对流-扩散场
9	扩散方程 ≈ 薛定谔方程	结构对称性：一个实数一个复数，是否有更深的映射?
10	矛盾论映射	主要矛盾=高权重块，对立统一=发散→停滞→汇聚
11	多源辩证语义引擎	法律+人文+社科知识库并行，user_context 影响对流方向
12	社会存在决定社会意识	用户画像（处境/阶级/经历）→ 对流方向偏移
13	“染料在有风的水中”	浓度场=相关度，风=query方向，水=文档图

十二、版本路线图

```
v1（当前目标，1-2 周）
  AD-Rank 核心算法 + 实验验证
  → 证明对流-扩散比纯扩散好
  → 产出：代码 + 实验数据 + 基础报告

v2（1-3 个月后）
  分块自适应对流（BAA）+ 多知识库
  → 法律+心理学+社会学并行检索
  → 用户状态向量影响对流方向
  → 产出：增强版算法 + 消融实验

v3（远期愿景）
  辩证语义引擎
  → 流场拓扑的汇聚=正题，发散=反题，停滞点=合题
  → 分支预测（预计算用户下一步的语义场）
  → 多知识库对流交叉=跨学科综合判断
  → 用户画像持续演化=对流方向随时间变化
```

附录：项目文件清单

文件	说明
CFD-RAG研究完整总结.md	本文件，主文档
参考论文清单.md	15 篇论文详细信息 + 关系图
AD-Rank技术全景图.md	7 张 Mermaid 概念图
ad-rank-demo.html	Three.js 3D 交互演示动画