Shape-CFD: Technical Report

Shape-CFD：基于形状感知对流-扩散方程的向量检索重排序算法

论文资料包 — 完整数学推导 · 实验数据 · 核心流程

> 作者：陈一凡 (Yifan Chen) 日期：2026-03-25 版本：v1.0 用途：论文撰写参考资料，不直接作为投稿稿件

第一部分：数学理论推导

1. 问题形式化

1.1 检索重排序问题定义

给定： - 查询向量 $q \in \mathbb{R}^d$（由预训练语言模型编码，$d = 4096$） - 候选文档集 $\mathcal{D} = \{d_1, d_2, ..., d_N\}$，其中每个文档已编码为 $v_i \in \mathbb{R}^d$ - 候选集由 HNSW 近邻检索的 top-N 结果构成（$N = 30$）

目标：学习一个排序函数 $f : \mathcal{D} \times q \to \mathbb{R}^N$，使得排序结果优于原始 cosine similarity 排序。

1.2 现有方法的局限

Cosine 直排：

$$\text{score}(d_i) = \frac{q \cdot v_i}{||q|| ||v_i||}$$

每个文档独立打分，忽略文档间的语义关联。当 query 存在多义性或候选文档形成语义聚类时，孤立打分无法利用文档间的互信息。

Cross-Encoder 重排序：

$$\text{score}(d_i) = \text{BERT}([q; d_i])$$

质量高但计算开销 $O(N \cdot L^2 \cdot H)$（L 为序列长度，H 为隐藏维度），$N = 30$ 时约 500ms。

---

2. AD-Rank 核心数学框架

2.1 图构建

Step 1: 相似度矩阵

$$S_{ij} = \cos(v_i, v_j) = \frac{v_i \cdot v_j}{\|v_i\|\|v_j\|}, \quad \forall i, j \in \{1, ..., N\}$$

Step 2: KNN 稀疏化

对每个节点 i，仅保留相似度最高的 k 个邻居：

$$\mathcal{N}(i) = \text{argTopK}_{j \neq i}(S_{ij}, k), \quad k = 3$$

Step 3: 边权重

$$W_{ij} = \exp(-\beta \cdot (1 - S_{ij})), \quad \beta = 2.0$$

权重随相似度指数衰减，β 控制衰减速率。

Step 4: 对称化

$$\#\#j \in \mathcal{N}(i) \ \#\#i \notin \mathcal{N}(j)\#\#text\#\#\#\#\#W_{ji} = W_{ij}$$

确保无向图性质，为扩散算子的对称正定性提供保证。

2.2 初始浓度场

$$C_0(i) = \cos(q, v_i), \quad i = 1, ..., N$$

物理解释：初始浓度等于文档与 query 的原始相关度，作为对流-扩散过程的初始条件。

2.3 对流方向推导

对每条边 (i, j)，对流系数定义为：

$$u_{ij} = \left\langle \frac{v_j - v_i}{\|v_j - v_i\|}, \frac{q}{\|q\|} \right\rangle \cdot u_{\text{strength}}$$

推导过程：

1. 边方向向量：$\vec{e}_{ij} = v_j - v_i$（从 i 指向 j）
2. 归一化：$\hat{e}_{ij} = \frac{\vec{e}_{ij}}{\|\vec{e}_{ij}\|}$
3. Query 方向：$\hat{q} = \frac{q}{\|q\|}$
4. 投影：$u_{ij} = (\hat{e}_{ij} \cdot \hat{q}) \cdot u_{\text{strength}}$

物理含义：$u_{ij} > 0$ 表示从 i 到 j 的方向与 query 方向一致（“顺风”），$u_{ij} < 0$ 表示逆向（“逆风”）。

反对称性证明：

$$u_{ji} = \left\langle \frac{v_i - v_j}{\|v_i - v_j\|}, \hat{q} \right\rangle \cdot u_{\text{strength}} = \left\langle -\frac{v_j - v_i}{\|v_j - v_i\|}, \hat{q} \right\rangle \cdot u_{\text{strength}} = -u_{ij}$$

因为 $v_i - v_j = -(v_j - v_i)$，且 $\|v_i - v_j\| = \|v_j - v_i\|$。■

2.4 守恒型 Upwind 格式

连续形式（对流-扩散方程）：

$$\frac{\partial C}{\partial t} = D\nabla^2 C - \nabla \cdot (\vec{u}C)$$

图离散化:

$$C_{t+1}(i) = C_t(i) + \Delta t \cdot \left[\underbrace{D \sum_{j \in \mathcal{N}(i)} W_{ij}(C_t(j) - C_t(i))}_{\#\#\#\#\#\#} + \underbrace{\sum_{j \in \mathcal{N}(i)} W_{ij}[\max(u_{ji}, 0) \cdot C_t(j) - \max(u_{ij}, 0) \cdot C_t(i)]}_{\#\#\#\#\#\text{upwind}\ \#\#\#\#\#\#} \right]$$

为什么必须用 Upwind 而非中心差分?

中心差分格式 $u_{ij} W_{ij}(C_j - C_i)$ 在 $\mathrm{Pe} > 2$ 时产生数值振荡。Upwind 格式通过选取上游节点的浓度值来保证传输方向的因果性:

- $u_{ij} > 0$（$i \to j$ 方向）：从 i 的浓度出发 $\to \max(u_{ij}, 0) \cdot C_i$
- $u_{ji} > 0$（$j \to i$ 方向）：从 j 的浓度出发 $\to \max(u_{ji}, 0) \cdot C_j$

全局守恒证明:

$$\sum_{i=1}^{N} F_i^{\text{adv}} = \sum_{i=1}^{N} \sum_{j \in \mathcal{N}(i)} W_{ij}[\max(u_{ji}, 0) C_j - \max(u_{ij}, 0) C_i]$$

由于 $u_{ji} = -u_{ij}$，每对 (i, j) 的贡献互为相反数，因此:

$$\sum_{i=1}^{N} F_i^{\text{adv}} = 0 \quad \blacksquare$$

系统总”浓度”（总分数）守恒，不会凭空产生或消失。

2.5 CFL 稳定性条件

为防止时间积分发散，时间步长必须满足 CFL 条件:

$$\Delta t \leq \frac{0.8}{\max_i |\mathcal{N}(i)|}$$

实际取 $\Delta t = \min(0.1, \Delta t_{\text{CFL}})$。

2.6 收敛条件

$$\max_{i \in \{1, \ldots, N\}} |C_{t+1}(i) - C_t(i)| < \epsilon, \quad \epsilon = 10^{-3}$$

2.7 双物理指标

动态 Reynolds 数（运行时指标）:

$$\mathrm{Re} = \frac{\sum_{i=1}^{N} |F_i^{\text{adv}}|}{\sum_{i=1}^{N} |F_i^{\text{diff}}|}$$

- $\mathrm{Re} > 1$: 对流主导
- $\mathrm{Re} < 1$: 扩散主导

结构 Péclet 数（静态指标）:

$$\mathrm{Pe} = \frac{\overline{|u_{ij}|}}{D} = \frac{\frac{1}{|\mathcal{E}|} \sum_{(i,j) \in \mathcal{E}} |u_{ij}|}{D}$$

- 不依赖浓度场 C，仅由图结构和 query 决定
- 零运行时开销（预计算即可）

2.8 自适应参数

Fiedler Value 自适应扩散系数:

拉普拉斯矩阵 $L = D_{\text{deg}} - W$ 的第二小特征值 λ_2（Fiedler value，代数连通度）:

$$D_{\text{adaptive}} = \frac{D_{\text{base}}}{1 + \lambda_2}$$

- λ_2 大（图紧密）→ D 减小，防止过度平滑
- λ_2 小（图分散）→ D 增大，增强信号传播

跨域检测自适应对流强度:

$$u_{\text{adaptive}} = u_{\min} + (u_{\max} - u_{\min}) \cdot \min\left(\frac{\sigma_{\text{sim}}^2}{0.04}, 1\right)$$

其中 σ_{sim}^2 为候选文档间相似度方差。

2.9 流场拓扑分析

稳态后，对每个节点计算散度:

$$\text{div}(i) = \sum_{j \in \mathcal{N}(i)} u_{ij} \cdot W_{ij} \cdot C(j)$$

分类: - $\text{div}(i) < -\theta$: **汇聚点**（convergence，高相关度吸引区） - $\text{div}(i) > \theta$: **发散点**（divergence，概率流出区） - $|dC/dt| < \theta'$: **停滞点**（stagnation，平衡区）

---

3. Shape CFD 扩展（核心创新）

3.1 动机

维度诅咒导致对流信号极弱:

在 d 维空间中，两个随机单位向量的内积满足:

$$\mathbb{E}[\langle x, y \rangle] = 0, \quad \text{Var}(\langle x, y \rangle) = \frac{1}{d}, \quad \sigma = \frac{1}{\sqrt{d}}$$

对 $d = 4096$: $\sigma = \frac{1}{\sqrt{4096}} \approx 0.0156$

实验验证: $\overline{|u_{ij}|} \approx 0.01$，与理论标准差高度吻合。意味着对流系数几乎为零——不是算法的问题，是高维几何的必然。

3.2 “向量不是点，是形状” 假设

将文档从单一向量升级为**句子级点云**:

$$d_i \to \mathcal{P}_i = \{s_{i,1}, s_{i,2}, \ldots, s_{i,K_i}\} \subset \mathbb{R}^d$$

其中 $s_{i,k}$ 是文档 d_i 的第 k 个句子的 embedding 向量。

3.3 Chamfer 距离

两个点云之间的距离：

$$d_{\text{Chamfer}}(\mathcal{P}_A, \mathcal{P}_B) = \frac{1}{|\mathcal{P}_A|} \sum_{a \in \mathcal{P}_A} \min_{b \in \mathcal{P}_B} d_{\cos}(a, b) + \frac{1}{|\mathcal{P}_B|} \sum_{b \in \mathcal{P}_B} \min_{a \in \mathcal{P}_A} d_{\cos}(a, b)$$

其中 $d_{\cos}(a, b) = 1 - \cos(a, b)$ 为余弦距离。

性质：- 对称性：$d_{\text{Chamfer}}(A, B) = d_{\text{Chamfer}}(B, A)$ - 非负性：$d_{\text{Chamfer}}(A, B) \geq 0$，等号当且仅当 $A = B$ - 自距离为零：$d_{\text{Chamfer}}(A, A) = 0$ - 捕获局部语义匹配：即使两个文档整体语义不同，只要部分句子高度相似，Chamfer 距离就会较小

3.4 Shape KNN 图

边权重用 Chamfer 距离替代 cosine：

$$W_{ij}^{\text{shape}} = \exp(-\beta \cdot d_{\text{Chamfer}}(\mathcal{P}_i, \mathcal{P}_j))$$

初始浓度：

$$C_0(i) = \exp(-2 \cdot d_{\text{Chamfer}}(\mathcal{P}_q, \mathcal{P}_i))$$

对流方向用**点云质心**：

$$\bar{v}_i = \frac{1}{K_i} \sum_{k=1}^{K_i} s_{i,k}, \quad u_{ij}^{\text{shape}} = \left\langle \frac{\bar{v}_j - \bar{v}_i}{\|\bar{v}_j - \bar{v}_i\|}, \frac{\bar{v}_q}{\|\bar{v}_q\|} \right\rangle \cdot u_{\text{strength}}$$

3.5 随机投影加速

为解决 Chamfer 距离的计算开销（$O(K_A \cdot K_B \cdot d)$），引入 Johnson-Lindenstrauss 随机投影：

$$\tilde{s} = P \cdot s, \quad P \in \mathbb{R}^{m \times d}, \quad m = 128$$

其中 P 的每个元素 $P_{ij} \sim \mathcal{N}(0, 1/m)$。

JL 引理保证：对任意 $\epsilon > 0$，当 $m \geq O(\epsilon^{-2} \log n)$ 时，

$$(1 - \epsilon)\|s_a - s_b\|^2 \leq \|\tilde{s}_a - \tilde{s}_b\|^2 \leq (1 + \epsilon)\|s_a - s_b\|^2$$

$m = 128$ 时，距离保持误差 $< 10\%$。

加速比：$d/m = 4096/128 = 32\times$

3.6 句子向量预缓存

- 离线阶段：对 23,701 个文档逐句 embed 并存入 SQLite（一次性成本）
- 在线阶段：查询时直接从 SQLite 读取 128 维投影向量
- 缓存命中后延迟：~3ms（对比无缓存的 1785ms embed API 调用）

第二部分：实验数据

4. 实验设置

4.1 数据集

属性	值
数据集	中国法律法规库
文档数	23,701 个法条 chunk
维度	4096 维 (Qwen3-Embedding-8B)
索引	USearch HNSW (M=32, ef=128)
候选数 N	30

4.2 测试 Query 集

#	Query	类型
1	劳动合同解除赔偿标准	单一法域
2	醉驾量刑标准	单一法域
3	离婚财产分割	跨法域 (民法+诉讼法)
4	借款合同利息上限	单一法域
5	房屋租赁合同纠纷	单一法域
6	交通事故责任划分	跨法域
7	知识产权侵权赔偿	单一法域
8	商标侵权赔偿	单一法域
9	行政处罚听证程序	单一法域
10	未成年人犯罪处罚	跨法域

4.3 评估方法

DeepSeek V3.2 盲评:

- A/B 匿名化：随机分配 cosine 排序和 Shape-CFD 排序为”方案 A”或”方案 B”
- 评分标准：1-5 分（相关性、覆盖度、排序合理性）
- 每次评审独立（无上下文记忆）

5. 核心实验结果

5.1 参数搜索（72 组网格搜索）

D	uStrength	knn	平均 Re	平均 Pe	收敛率	最优
0.05	0.1	3	0.892	0.195	80%	
0.10	0.1	3	0.756	0.098	90%	
0.15	**0.1**	**3**	**0.695**	**0.065**	**100%**	☆
0.20	0.1	3	0.623	0.049	100%	
0.15	0.3	3	—	—	40%	
0.15	0.5	3	—	—	10%	

最优配置：$D = 0.15, u_{\text{strength}} = 0.1, k = 3$

5.2 AD-Rank v2 vs Cosine 盲评

Query	v2 得分	Cosine 得分	胜方
劳动合同解除赔偿	3	3	平
醉驾量刑标准	2	3	cosine
离婚财产分割	4	3	**v2**
借款合同利息上限	4	2	**v2**
房屋租赁合同纠纷	3	3	平
交通事故责任划分	4	2	**v2**
知识产权侵权赔偿	3	3	平
商标侵权赔偿	4	2	**v2**
行政处罚听证程序	5	3	**v2**
未成年人犯罪处罚	2	4	cosine
平均	**3.4**	**2.8**	**v2 胜 7:2 (1平)**

5.3 全策略横评（7 组 × 10 query × 60 次盲评）

Rank	方案	盲评分	Pe	速度	收敛率	胜/负
	AD-Rank v2	**3.4/5**	0.065	14.8ms	**100%**	**7/2**
	BAA 分块	3.3/5	0.226	7ms	20%	7/3
	v2+PCA	3.2/5	0.112	33ms	90%	6/4
4	v2+自适应	3.0/5	0.122	3.3ms	100%	5/4
5	v2+温度	2.9/5	0.604	3.5ms	10%	5/5
6	MDA	2.7/5	0.351	85.8ms	0%	3/7

关键发现：Pe 高 ≠ 排序好。弱对流 + 强扩散是最佳平衡。

5.4 Shape CFD 独立实验

维度	AD-Rank v2	Shape CFD	改进
盲评分 (vs cosine)	3.3/5	**3.4/5**	+3%
胜率 (vs cosine)	6:4	**8:2**	+33%
Pe (Péclet 数)	0.065	**0.281**	+332%
收敛率	100%	100%	—
速度 (缓存加速后)	14.8ms	**22ms**	+49% 可接受

5.5 速度优化历程

版本	延迟	加速比	手段
v0 原始	1031ms	1×	JavaScript 朴素实现
v1 缓存	29.7ms	35×	SQLite 向量缓存

v2 极致	2.2ms	468×	平铺 Float64Array + 8 路展开
Shape v0	1837ms	—	每次调 API embed 句子
Shape v1	**22ms**	**84×**	句子预缓存 + 128 维投影

第三部分：核心流程

6. 算法流程图

```
输入: query 文本 + 知识库

Step 1: Query Embedding
  query → Qwen3-Embedding → q ∈ R^4096

Step 2: HNSW 粗筛
  q → USearch HNSW → top-30 候选 {v_1, ..., v_30}

Step 3: 点云构建 (Shape CFD)
  对每个候选文档:
    拆句 → 读 SQLite 缓存 → 128 维投影点云
  对 query:
    实时 embed → 128 维投影

Step 4: Shape KNN 图构建
  30×30 Chamfer 距离矩阵 → KNN 稀疏化 (k=3)
  边权重: W_ij = exp(-2 × d_Chamfer)

Step 5: 初始浓度 + 对流方向
  C_0(i) = exp(-2 × d_Chamfer(q, d_i))
  u_ij = dot(centroid_j - centroid_i, query_dir) × u_strength

Step 6: 对流-扩散迭代
  while (maxDelta > ε and t < maxIter):
    C_{t+1} = C_t + dt × [扩散 + upwind 对流]
    检查 CFL 条件

Step 7: 拓扑分析
  计算每个节点散度 → 标记汇聚/发散/停滞点

Step 8: 排序输出
  按 C 降序 → top-K → 返回给 LLM

输出: 重排序后的 top-K 法条 + 物理指标 (Re, Pe)
```

7. 代码架构

文件	行数	职责
`ad_rank.js`	885	核心求解器 v2 (含自适应参数)
`ad_rank_shape.js`	869	Shape CFD (Chamfer + 点云 + 缓存加速)
`ad_rank_data.js`	414	数据接口 (USearch + SQLite)
`ad_rank_shape_cache.js`	329	句子向量预热脚本
`ad_rank_v3.js`	~400	MDA / BAA 策略实现
`ad_rank_final_eval.js`	~480	全策略横评

第四部分：与已有工作对比

8. 相关工作定位

方法	年份	扩散	对流	形状	自适应	可解释
Cosine Similarity	—	×	×	×	×	×
PageRank (Brin 1998)	1998	类似	×	×	×	×
Diffusion-Aided RAG	2025		×	×	×	×
Gaussian Embeddings	2014	×	×	(分布)	×	×
GELD	2024	×	×	(高斯)	×	×
Cross-Encoder	2019	×	×	×	×	×
AD-Rank (Ours)	**2026**			×		
Shape-CFD (Ours)	**2026**					

独创组合：形状表示 + 对流-扩散方程 + 检索重排序 + 自适应参数 + 物理可解释性

第五部分：待补充项（论文投稿前必须完成）

9. 短板清单

#	待补充	重要性	预估工作量
1	**公开数据集实验** (MS MARCO / BEIR)	必须	2-3 天
2	**NDCG@10 / MRR 标准指标**	必须	随上一项完成
3	**与 Neural Reranker 对比** (BGE-Reranker)	必须	1 天
4	收敛性理论证明	🟡 建议	需数学协助
5	更大候选集 ($N = 100$) 的 scalability 测试	🟡 建议	半天
6	人工标注评估 (替代 LLM-as-Judge)	🟡 建议	视资源

第六部分：参考文献

1. Vilnis & McCallum. “Word Representations via Gaussian Embedding.” ICLR 2015.
2. Yang et al. “Diffusion-Aided RAG.” ACL 2025.

3. Noack et al. “Advection-Augmented CNN.” arXiv 2024.
4. Page et al. “The PageRank Citation Ranking.” Stanford InfoLab, 1998.
5. Bruna et al. “Spectral Networks and Deep Locally Connected Networks on Graphs.” ICLR 2014.
6. Kipf & Welling. “Semi-Supervised Classification with Graph Convolutional Networks.” ICLR 2017.
7. Johnson & Lindenstrauss. “Extensions of Lipschitz mappings into a Hilbert space.” AMS, 1984.
8. Rubner et al. “The Earth Mover’s Distance as a Metric for Image Retrieval.” IJCV, 2000.
9. Fan et al. “A Point Set Generation Network for 3D Object Reconstruction.” CVPR 2017.
10. Reimers & Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks.” EMNLP 2019.
11. Nogueira & Cho. “Passage Re-ranking with BERT.” arXiv:1901.04085, 2019.
12. Cuturi. “Sinkhorn Distances: Lightspeed Computation of Optimal Transport.” NeurIPS 2013.
13. Zhao et al. “GRAND: Graph Neural Diffusion.” ICML 2021.
14. Chamberlain et al. “BLEND: A Framework for Graph Neural Diffusion.” ICLR 2021.
15. Li et al. “DiffuSeq: Sequence to Sequence Text Generation with Diffusion Models.” ICLR 2023.